

青序量化研究平台

可复现的多因子研究与风险控制

2026 年 9 月 21 日 最终提交报告 平台 v2.0 (Python)

1 研究问题与主要结论

在可核验的账本上，比较简单因子、预测模型与风险约束。

Project 1 的主体是正确、完整、可复现且可扩展的研究平台。按课程课件，基础项占 80 分、扩展项占 20 分，没有强制收益或 Sharpe 门槛。本报告以数据质量、信息时点、实际成交与实验控制为主线，同时检验扣费收益是否超过同期中国 CPI。

沿用 2019 年末选定的 1,000 只主板股票，使用 2019-10-08 至 2026-09-18 的 1,656,599 条日线。新增每日估值、历史财报与行业区间，构建 12 个有经济解释的因子。候选包括标准化等权多因子、中性化多因子、Ridge、LightGBM 和小型 MLP。模型训练截至 2022 年，2023-2024 年用于选择，2025 年之后仅用于评估。

最终预选策略	累计净收益	年化净收益	最大回撤
标准化多因子+风险控制	6.12%	3.65%	7.01%

最终评估为 2025-01-02 至 2026-09-18，共 417 个交易日。Sharpe 为 0.573，平均现金比例 51.74%。在 2025 年 2 月至 2026 年 8 月的 19 个共同完整月份内，策略累计 7.02%，CPI 累计 0.69%，实际购买力收益 6.29%。跑赢同期 CPI 且回撤低于 20% 的研究目标达成；年化 5%-8% 的较高期望未达成。

同期沪深 300 价格指数年化 8.55%、回撤 12.05%。提交策略降低了风险，也牺牲了上涨参与度，不能据此宣称战胜市场或显著 alpha。LightGBM 后续表现较好，但验证期为负收益，未用最终期排名替换预选策略。


交付与证据导航

平台包含策略研究、交互回测、因子诊断、数据复现及扩展指南。仓库提供源码、测试、固定依赖、合成样本与真实研究汇总。配套本报告、20 页 Beamer 演示、可编辑 PowerPoint、讲稿和提交清单。第 2-6 页说明实现，第 7-9 页说明实验，第 10 页逐项核验与披露边界。

2 架构、接口与可维护性

数据、分数、目标权重、成交和统计分别承担独立职责。

选择 Python，复用 NumPy、pandas、SciPy、scikit-learn 及 LightGBM。Streamlit 和 Plotly 负责交互；界面不实现第二套收益计算。参考 Qlib 的因子表达与训练/验证 workflow，保留透明的小型会计引擎，以便逐项核对课程的缺失、费用和标签口径。Backtrader 仅作为独立参考测试依赖。



模块	输入、输出与职责
data / incremental	厂商响应转统一行情；原始响应与标准数据分开，重复键报错，增量合并另写新目录。
factors / features	三个注册式基准因子及 12 个扩展因子；完整日历对齐，输出长表或日期 × 资产面板。
models	只对训练区间拟合，输出后续分数与固定参数、随机种子。
risk / portfolio	分数变为目标权重；保留缓冲、波动率预算及行业/单股上限。
engine	下一开盘执行、现金约束、涨跌停、部分成交、缺失估值及逐日账本。
analytics	IC、分组、收益与回撤；独立从成交重建现金和单位余额。
experiment / research	配置、数据和源码哈希，固定对照、时间分割、选择记录、历史运行归档。
app / ui_research	调用核心或读取已落盘研究结果，导出 CSV/PDF，不在刷新时偷偷重训。

核心数据契约

行情键为 `date`，`asset`；因子长表为 `date`，`asset`，`factor`，`value`，高分方向在实验前固定。目标权重保留同样日期和资产轴，要求有限、非负且和不超过 1。成交结果分为 `daily`、`trades`、`positions`、`orders`，拒单原因和部分成交均留痕。CLI 与界面使用同一配置与函数。

扩展路径与版本

新增技术因子注册 `FactorSpec`；基本面因子显式声明公告滞后；预测模型只输出相同面板。新组合只替换权重构建，成交与分析无需改写。完整研究重跑前归档旧目录；特征缓存核对输入文件及源码指纹，避免把旧特征冒充新版本。公开仓库不包含 `Token` 或厂商逐股原始数据。

3 数据来源、质量与偏差

固定选池日先于所有收益研究，历史缺失保留并计数。

2019-12-31 按当日成交额取符合主板代码、价格至少 3 元且有成交的前 1,000 只，并列按代码。没有使用今日仍上市名单，后来停止报价的原成员也保留。该池不包括 2020 年以后 IPO，单日流动性选择偏向当时热点，结论不代表全 A 股或沪深 300。

核验项目	数量或结果
统一日线 / 日历交易日	1,656,599 / 1,690
完整股票 × 日历网格缺行	33,401
重复行情键 / 异常剔除	0 / 0
涨跌停价格缺失 / 最新有报价资产	48 / 956
每日估值记录 / 重复键	1,656,599 / 0
财务指标记录 / 单次返回最高行数	57,389 / 67 (接口上限 100)
行业历史区间 / 特征网格	1,432 / 1,690,000
原行情清单哈希 / 新研究清单哈希	3,006 / 2,073 个文件通过

来源接口	字段、单位与用途
daily / adj_factor	OHLC 原价为元/股，vol 源单位手转股；统一乘法复权供收益计算。
stk_limit / trade_cal	原始涨跌停价和完整交易日历；缺限制价时不执行对应方向。
daily_basic	total_mv 为万元，PE/PB 为倍数，dv_ttm 与换手率为百分数；每日横截面。
fina_indicator	ann_date 为公告日，end_date 为报告期；ROE 为百分数，严格滞后使用。
index_member_all	申万一级行业进出区间；未知或冲突标 UNKNOWN，不将当前行业反填历史。
index_daily / cn_cpi	沪深 300 价格指数；全国 CPI 月环比，按共同完整月份比较。

复权、可得性与存储

所有 OHLC 用 $P_{i,t}^{adj} = P_{i,t}^{raw} A_{i,t} / A_{i,ref}$ ，每资产固定首个有效参考因子。行情及研究数据合计约 1.63GB，包括原始缓存、标准数据、特征和模型分数。原始请求记录字段、日期与 UTC 下载时间，保存 SHA-256；同请求可断点续拉。

历史行业未知比例约 0.52%，年度 ROE 平均覆盖约 98.90%（按每日合资格样本计算）。采用公告时点仍不能消除厂商事后修订，当前数据不是完整的逐版本财报库。保留此局限，不用“无未来函数”概括所有数据风险。

4 因子设计与标准接口

12 个因子覆盖不同假设，经济方向固定，负结果同样保留。

记 C, H, L, V 为同尺度价格与股数， $r_t = C_t/C_{t-1} - 1$ 。下表所有分数均为“越大越优先”的事前方向，缺失不补未来值。完整字段、窗口、失败情形和实现位置见 `docs/FACTOR_CARDS_V2.md`。

因子	公式与窗口	主要假设或风险
中期动量	$C_{t-20}/C_{t-60} - 1$	跳过短期反转；趋势突变失效
短期反转	$-(C_t/C_{t-5} - 1)$	超调修复；持续下跌失效
低波动	$-s(r, 20)$	防御性；牛市可能落后
低振幅	$-(H - L)/\overline{C}_{20}$	日内风险；与低波动冗余
均线趋势	$C_t/\overline{C}_{20} - 1$	趋势延续；震荡易反复
量能变化	$\log(\overline{V}_5/\overline{V}_{20})$	量能确认；方向可能不稳定
流动性	$-\overline{ r }/(\overline{C^{raw}V}/10^6)_{20}$	冲击较低；可能偏大盘
低换手	$-\text{turnover_rate}$	降低拥挤；也可能缺乏交易
盈利收益率	$1/PE_{TMM}, PE > 0$	价值；亏损公司无定义
账面市值比	$1/PB, PB > 0$	价值；资产质量有差异
股息率	$dv_{TMM}/100$	分红；历史分红不可保证
盈利质量	最新已公告年度 $ROE/100$	盈利能力；财报修订与滞后

动量和反转要求整个价格窗口完整，波动等滚动统计要求完整观测；不将停牌前后压缩为相邻日。PE/PB 非正为缺失，财报同公告、同报告期的冲突副本剔除，年度报表超过 550 日不再使用。建模时至少 10 个有效因子；剩余标准化缺值填 0 表示当日横截面中性值，不将缺失收益标签填 0。

基础项与扩展项的关系

原始 20 日动量、5 日反转、20 日低波动保留注册入口，可独立调窗口、诊断和回测。12 因子研究采用固定配方，标准化等权平均为一个透明基线。中性化改变行业/市值暴露，不保证提高收益；本次没有因为某因子最终 IC 为负而翻转符号。

与 Qlib 和参考文献的关系

参考 Qlib Alpha158 中的滞后、滚动量价表达以及训练/验证分离，复用 LightGBM 和 scikit-learn 模型实现。此处 12 因子是明确列出的自定义子集，**未声称完整复制 Alpha158，也未将 Qlib 引擎集成进主账本**。CogAlpha 论文采用代码形式的因子与 LLM 演化搜索，本项目借鉴可检查的因子表示，未开展大规模自动搜索。

5 中性化、标签与模型比较

每日横截面处理

合资格条件为原价至少 3 元、过去 20 日平均成交额至少 2,000 万元、市值有效、至少 10 个因子有效，并以涨跌停比例排除近似 5% 限制样本。最后一项只是 ST 类风险代理，不等于完整历史 ST 名单。每个形成日单独对因子取 1%/99% 分位数截尾，使用当日均值和样本标准差得到 $z_{i,t}$ 。中性化回归为

$$z_{i,t} = \sum_g \alpha_{g,t} \mathbf{1}\{industry_{i,t} = g\} + \beta_t \log(MV_{i,t}) + \epsilon_{i,t}, \quad n_{i,t} = \epsilon_{i,t} / s_t(\epsilon).$$

实现用分组去均值后回归市值，等价于包含行业虚拟变量的 OLS 残差。测试核验行业内残差均值为 0、残差与市值正交。UNKNOWN 作为单独组，不能凭当前行业补历史。

信息时间轴

区间	用途
2019 年 10 月起	因子预热，选池日在 2019-12-31
2020–2022	模型训练，有效训练样本 653,622 条
2023–2024	五个候选的验证与唯一选择
2025-01-02–2026-09-18	417 日最终评估，禁止据此替换预选模型

收盘 t 标签为 $y_{i,t} = O_{i,t+21} / O_{i,t+1} - 1$ 。训练目标使用当日横截面标签百分位秩减 0.5，保留相对收益排序信息；跨入 2023 年的训练标签剔除。财务数据在公告日之后才可用；任何全样本标准化都被禁止。

固定模型与选择规则

Ridge 的 $\alpha = 100$ ；LightGBM 使用 250 棵树、学习率 0.03、15 叶、最大深度 5、叶最少 500 样本、L2=10；MLP 为 12–32–16–1，ReLU、Adam、8 个固定训练轮次，种子 20260921。MLP 在预算内未收敛，结果只代表该固定配置。表格特征没有天然相邻顺序，本次选择小型全连接网络而非在任意因子顺序上卷积。

优先选择验证期年化为正且回撤不超过 20% 的候选，再按年化收益/最大回撤排序。先保存 selection.json，再进入最终期。原动量全区间表现已被看过，因此本次最终段不是完全未知的盲测；这一程序控制不能消除所有研究者选择风险。

6 组合、成交与账本核验

每笔费用来自实际成交金额，模型只决定分数。

每 20 个交易日调仓，目标 50 只。原持仓仍在前 70 名则优先保留，其余按分数补足，减少边界换手。先按波动率倒数构建权重，单股目标不超过 4%、行业目标不超过 25%；上限造成的余量留现金，不强制重新分配。

过去 60 日的候选组合收益估计年化波动率 $\hat{\sigma}$ 。股票总预算为

$$e_t = 0.90 \min\{1, 0.12/\hat{\sigma}_t\} \times \begin{cases} 1, & CSI300_t \geq MA_{120,t}, \\ 0.25, & \text{其他情况.} \end{cases}$$

再应用个股与行业上限。所有估计截至形成日，次日开盘执行。风险估计中的少量历史缺价按 0 收益处理，是可低估风险的近似；实际缺价成交仍受阻。权重、波动和 20% 回撤均为目标，不能保证市场变化后的实际风险。

成交与估值规则

开盘按目标名义金额计算连续可分的复权单位，先卖后买，保留费用缓冲，现金不足同比缩减买单。涨停不买、跌停不卖、缺开盘或限制价不成交。每资产成交预算不超过此前 20 日平均成交额的 1%，超过时部分成交；这是事前容量代理，不是当日成交量的真实参与率保证。

$$fee_t = 0.001 BuyNotional_t + 0.0015 SellNotional_t, \quad Turnover_t = \frac{BuyNotional_t + SellNotional_t}{OpeningNAV_t}.$$

买 10bp、卖 15bp 是统一研究假设，不冒充历史法定税费。停牌持仓沿用最后已知收盘价并计数，连续缺失超过 20 个交易日保守计零；保留单位，恢复报价时重新估值，不虚构卖出。复权单位近似分红自动再投资，尚未模拟整手、完整分红现金或结算规则。


独立核验与扩展测试

从成交逐笔重建现金与单位余额，再核对每日 NAV、费用、换手与收益连乘。13 个主研究运行全部通过，每次检查 417 或 484 个交易日。数值容差现金绝对 10^{-6} 元、相对 10^{-10} 。测试另覆盖手算、拆股连续性、独立 Backtrader 参考、未来扰动、公告滞后、中性化残差、无杠杆、部分成交及增量幂等。另以大面板逐项除法复现并修复本机可选 NumExpr 加速的错误常数结果，统一禁用该路径并重新生成全部研究；独立账本不能替代上游数值验证。最终测试与复算日志见验收清单。

7 原始动量为何亏损

原账本能够复核，亏损不能只归因于费用。

原始策略为 20 日动量、前 30 只等权、每 5 个交易日调仓。2020-01-02 至 2026-09-18 累计净收益为 -83.57%，最大回撤 89.83%，费用 254,496.22 元。2022-2024 连续大幅亏损，说明该固定样本和持有方式下的趋势假设没有稳定兑现。



口径	全区间累计收益	含义
原始扣费账本	-83.57%	实际模拟路径
同成交路径加回费用	-58.12%	费用退回闲置现金
零费用独立重跑	-75.16%	仓位规模随无费用净值变化

费用确实侵蚀收益，但零费用重跑仍亏损 75.16%。两个“毛收益”口径差异来自再投资与路径依赖，不能把累计费用简单加回当作可执行零费策略。原实验日均双边换手约 20%，长期高频再平衡增加了成本拖累。

同区间重新比较

为避免把六年旧策略与不到两年新策略直接比较，原动量在 2025-01-02 重新从 100 万元启动。该期累计净收益 -6.02%、最大回撤 33.46%、费用 101,397.93 元。新预选策略为 6.12%、7.01% 和 7,692.31 元。两者同时改变了因子与组合，所以这是**整体系统比较**，不能把差额全部归因于某一个因子。

能下的结论与不能下的结论

账本、拒单和缺失估值均有证据，不支持把亏损直接判成程序记账错误。新策略减少换手与市场暴露，并引入防御/价值等因子；究竟哪项贡献最大需要单变量对照。固定池、行业暴露、停牌估值和成本假设仍会影响结果，未完成逐笔市场微观结构归因。

8 模型选择与最终区间表现

验证期选出的简单基线保留为提交策略。

所有候选使用相同股票池、期间、费用与风险规则。原始标准化等权基线使用 z 分数，其余学习模型使用中性化特征，因此模型间差异不能脱离输入处理解释。标准化基线与中性化等权基线构成预处理对照。

验证期 2023–2024	年化净收益	最大回撤	Sharpe	平均现金
标准化多因子	5.84%	7.20%	0.987	61.81%
中性化多因子	0.63%	10.55%	0.125	58.87%
Ridge	2.84%	12.58%	0.396	66.38%
LightGBM	-2.21%	13.05%	-0.290	61.67%
小型 MLP	0.33%	9.57%	0.082	62.69%

验证期标准化多因子年化 5.84%、回撤 7.20%，风险收益比最高。中性化和复杂模型未稳定提高验证收益，故没有把复杂度当作选择理由。

最终期 2025–2026/9/18	年化净收益	最大回撤	Sharpe	平均现金
标准化多因子	3.65%	7.01%	0.573	51.74%
中性化多因子	5.36%	10.26%	0.644	41.45%
Ridge	7.12%	10.66%	0.769	49.90%
LightGBM	13.09%	11.69%	1.318	42.45%
小型 MLP	5.76%	10.31%	0.657	45.15%

LightGBM 最终期年化 13.09%，但验证期为 -2.21% ，不能后验替换模型。提交策略年化 3.65%、波动 6.64%，CPI 目标达成但未达到更高的年化期望。



沪深 300 为价格指数且未扣复制成本，未含现金分红，策略则采用复权研究单位；两者不是完全对等的可投资基准。最终评估始终从独立 100 万元现金启动，不与验证期拼接冒充连续实盘。


9 因子诊断、压力测试与不确定性

每日横截面先计算 Pearson IC 和 Spearman Rank IC（并列平均秩），再汇总时间均值和样本标准差；至少 30 个有效配对，常数或不足样本为 NaN。下表为 2023-01-03 至 2026-08-18 的 878 个形成日、20 日未来标签，展示中性化因子。标准化前后对照另存 preprocessing.csv。

因子	平均 IC	平均 Rank IC	平均覆盖率
中期动量	-0.0035	-0.0161	89.72%
短期反转	0.0176	0.0187	90.18%
低波动	0.0378	0.0722	90.18%
低振幅	0.0377	0.0789	90.18%
均线趋势	-0.0230	-0.0321	90.18%
成交量变化	-0.0116	-0.0171	90.18%
流动性	-0.0415	-0.0514	90.18%
低换手	0.0443	0.0655	90.18%
盈利收益率	0.0169	0.0428	75.23%
账面市值比	0.0191	0.0515	90.18%
股息率	0.0147	0.0374	71.42%
盈利质量	0.0042	0.0068	89.28%

低振幅与低波动 Rank IC 较高，但信息有重叠；流动性和趋势方向在此样本为负，未事后翻转。分组先用当日分数固定五组，再匹配未来收益，分别记录形成数与有效数。重叠 20 日标签的分组均值及高低组差是诊断量，不能连乘成可交易净值，不能据此声称独立样本显著性。

相同分数下的组合与费用对照



取消整套风险构建、改为满仓等权后，年化 4.81%、回撤 13.12%；风险组合为 3.65%、7.01%。这是组合模块整体对照，不能单独识别趋势或波动控制的贡献。双倍费用下年化 3.18%、回撤 7.24%，说明低换手改善了费用耐受性。

共同完整月份 2025/02–2026/08 中，按 CPI 月环比连乘：策略 7.02%，通胀 0.69%，实际收益 6.29%。不把同比连乘，也不把部分 9 月与整月 CPI 比较。对已实现净收益作 20 日循环分块、2,000 次 bootstrap，年化收益 95% 分位区间为 [-4.73%, 14.13%]。该区间仅是固定策略的条件性描述，未涵盖模型选择及未来市场结构变化，不能保证未来跑赢通胀。

10 课程核验、复现与研究边界

课程要求	已交付的实现与证据
数据与质量	原始/标准分离、字段单位、复权尺度、缺失和异常报告、源文件哈希。
至少 3 因子	原 3 个可配置因子+ 12 因子卡，统一长表，经济方向与缺失规则明确。
回测与输出	日期/调仓/持仓/成本可配置，实际成交费用，净值、持仓、成交和订单导出。
IC 与分组	日横截面 IC/Rank IC、样本量/覆盖/分布；先分组再匹配标签。
绩效与实验	初始 NAV 参与回撤，252 日年化，固定控制变量，保留失败与选择协议。
正确性与复现	手算和独立参考、时点扰动、账本核对，源码/数据/参数指纹、测试及 CI。
扩展项	历史中性化、风险权重与现金、事前流动性部分成交、增量合并幂等和修订审计。
提交材料	可运行代码/依赖/README/样本，10 页 PDF，本地完整数据获取指南，Beamer 及 PPTX。

复现入口

安装固定依赖与 `.[dev,research]`，运行 `python -m pytest -q` 并运行演示命令：

```
python -m cfquant.cli run --config configs/demo.yaml
```

。真实实验先按 `EXPANDED_DATA.md` 下载固定 1,000 股行情，再运行补充数据脚本及 `python -m cfquant.cli research`，最后发布证据并生成报告。无 Token 仍能演示合成样本和已发布真实研究摘要，不能重拉厂商数据。完整步骤见 `REPRODUCE_V2.md`。

行情 SHA-256:

```
7fecc242fe6450c3aeb0a4024621c6b6fa3f230540eacb5dc9b4c006af7adf4
```

原始 60 股、扩展旧动量与升级研究分别保留身份，不混用区间。本地运行归档与公开 Git 提交提供版本历史；公开仓库只含可分享合成数据和派生汇总。

限制与后续方向

固定历史池、厂商修订、行业重构、ST 代理、长期缺失计零、连续复权单位以及固定费用均限制外推。风险目标不是硬保证，MLP 预算不足以代表神经网络上限。最终区间曾被原始动量研究观察，全部结果为描述性。后续在新的未观察区间采用滚动训练、动态历史股票池、真实分红现金与整手成交，并以严格验证检验更多 Qlib 因子，不能反复挑选当前最终期冠军。

主要依据与工具来源

1. 课程原件 `CF2026_Project1.pdf` (19 页)：评分结构、交付、会计与因子诊断口径。
2. Microsoft Qlib: <https://github.com/microsoft/qlib>, Alpha158/LightGBM 公开基准配置与量价表达。
3. Liu et al., Cognitive Alpha Mining via LLM-Driven Code-Based Evolution, v4: <https://arxiv.org/abs/2511.18850v4>。
4. Tushare Pro 官方文档: https://tushare.pro/document/2?doc_id=32 (估值); `doc_id=79` (财务, 单次 100 行); 335 (历史行业); 228 (CPI); 27/28/183/26 (日线/复权/限制/日历)。
5. scikit-learn: https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html; LightGBM: <https://github.com/microsoft/LightGBM>; Backtrader: <https://github.com/mementum/backtrader>。